

Лицензируемый слой персонажа: предмет разработки и его экономика

Что именно строится вокруг AI-девайса, при каких условиях каждая часть конструкции сходится, сколько стоит её создание и сопровождение, и что из построенного переносится на внешние рынки, а что делается заново.

ГОРИЗОНТ	ПЕРВЫЙ РЫНОК	МОДЕЛИ ЭКОНОМИКИ	СТАТУС
18 месяцев, три фазы	Россия, как референс	На устройство и на лицензиата	Проектный документ

ЦЕНТРАЛЬНЫЙ ТЕЗИС

У Анимаккорда сегодня два профильных актива: производство сериала и лицензирование. Предлагается третий, того же типа — лицензируемый слой персонажа: канон, голос, память и приёмка, упакованные так, что их можно продавать лицензиатам как право.

Россия в этой конструкции — **референс-инсталляция**: единственное место, где компания держит весь стек целиком и получает на выходе не столько выручку, сколько доказательства — реальную себестоимость минуты, удержание, историю безопасности, отлаженный канон. Дальше на внешние рынки уходит пакет с доказательствами, и роялти растёт без капитальных затрат.

01 Executive summary	02 Четыре архетипа	03 Benchmark-матрица
04 Требования к ТЗ	05 Регуляторный контур	06 Экономика категории
07 Экономика AI: мир и РФ	08 Российский контур	09 Ландшафт платформ
10 Возрастной разрыв	11 Сценарии, включая пятый	12 Предмет разработки
13 Unit economics	14 Гипотезы	15 Ориентиры по фазам
16 Метод и источники		

01 – Executive summary

Пять условий, которые задают конструкцию

01

Железо не несёт модель — значит, в модели должен быть повторяющийся платёж

У Tonies в 2025 году колонки дали 26% выручки, фигурки — 71%: контент приносит в 2,8 раза больше железа. У продуктов без повторяющегося платежа выручка заканчивалась в момент продажи, и все крупные из них ушли с рынка в 2018–2019 годах.

Следствие: в конструкции должна быть хотя бы одна из трёх форм повторяющегося платежа — носители контента, подписка, роялти с лицензии. Разобраны в разделе 11; сценарий 5 использует третью.

02

Валовая маржа высокая, операционная — тонкая: расходится всё между ними

Железо в категории дешёвое. Отраслевые ориентиры валовой маржи — 50–65% в массовом сегменте, 70–85% в среднем и свыше 90% в премиальном; контрактный производитель зарабатывает несколько юаней с изделия, продающегося за несколько сотен. У Tonies валовая маржа 62,8%.

Расстояние до операционной прибыли и есть содержание вопроса: при выручке €630,3 млн и базе 11,8 млн устройств скорректированная EBITDA — 8,6%, свободный денежный поток за 2025 год отрицательный. Между двумя цифрами стоят розница, берущая 40–60% валовой маржи, дистрибьюторы с наценкой 20–40%, маркетинг, логистика и постоянная команда. Лицензиарам Tonies платит 11,0% выручки — €69,4 млн.

Следствие: дешёвое железо даёт запас на входе, и удерживает его то, что стоит после валовой маржи, — устройство канала, повторяющийся платёж и стоимость сопровождения. Собственная модель имеет смысл при доходности выше 11% с оборота экосистемы: столько даёт чистое лицензирование при нулевых вложениях. Сценарий 5 сконструирован так, чтобы брать и роялти, и маржу на инференсе.

03

Живой диалог стоит \$13–25 на пользователя в месяц — гибридная архитектура обязательна

15 минут живой генерации в день на мировом стеке дают \$13–25 в месяц; на российском при подписке 299–399 ₽ в бюджет помещается **1,8–3,0 минуты живого диалога в день**. Разница между стеками — в пределах погрешности, см. раздел 07.

Следствие: гибридная архитектура с квотой входит в ТЗ как требование уровня P0. Предзаписанный контент несёт основную часть времени использования, живая генерация метрируется. Отсюда же вытекает ценность локального инференса именно на российском рынке.

04

Подписка в детском hardware поздняя и небольшая

У Tonies спустя десять лет «Accessories & Digital» — 3,5% выручки. У Yoto подписка даёт около 25%, механика там — кредиты на физические карточки, скидки и доставку. Медианный месячный отток детских образовательных подписок — 7,4%.

Следствие: подписку нельзя закладывать как основной источник в первые 18 месяцев. Способ обойти отток — бандл с уже существующей подпиской, а не отдельная строка в чеке; гипотеза H6.

05

Возрастной разрыв — структурное ограничение срока окупаемости

Ядро аудитории франшизы — 2–6 лет; устройству для окупаемости нужно 3–5 лет жизни в семье. В детских подписках 24% отписок приходится на «ребёнок перерос контент» и 36% — на «потерял интерес».

Следствие: разрыв влияет на срок окупаемости и на выбор метрики успеха. Варианты смягчения внутри франшизы — раздел 10.

Что из этого следует для конструкции продукта

Пять условий сходятся в одну архитектуру: устройство с обязательным офлайн-режимом, предзаписанная библиотека как основа времени использования, метрируемый слой живого диалога поверх неё, и **ядро, отделённое от рынка** — чтобы то, что построено в России, продавалось дальше как право.

С появлением голоса предметом лицензии становится вместе с изображением и поведение персонажа. Ядро, которое это поведение задаёт и принимает перед выпуском, поэтому входит в условия лицензии — и отгружается в уже существующую сеть лицензиатов франшизы.

Состав ядра, три строки затрат и граница между переносимым и непереносимым — раздел 12. Это основная часть документа; всё предыдущее — фактура, на которой она стоит.

02 — Ландшафт

Четыре архетипа и условия, при которых каждый работает

Классификация по тому, что пользователь покупает во второй раз.

АРХЕТИП	ЧТО ПОКУПАЮТ ВТОРОЙ РАЗ	ПРИМЕРЫ	ДОЛЯ RECURRING	ПРИ КАКИХ УСЛОВИЯХ СХОДИТСЯ
A. Content device	Физические носители контента	Tonies, Yoto, Storypod, Lunii, Faba	70–75%	При каталоге в тысячи наименований и повторных покупках порядка 4–6 в год. Единственный архетип с публично подтверждённой прибыльностью — и та на уровне 8,6% EBITDA
B. Ecosystem device	Сервисы и медиа-подписка платформы	Echo Kids, Nest	н/д	При наличии у владельца собственного маркетплейса или медиа-подписки, на которую устройство приводит. У Amazon экосистемная выручка не покрывала субсидию железа

АРХЕТИП	ЧТО ПОКУПАЮТ ВТОРОЙ РАЗ	ПРИМЕРЫ	ДОЛЯ RECURRING	ПРИ КАКИХ УСЛОВИЯХ СХОДИТСЯ
C. AI companion	Подписку на расширенный AI и контент	Miko, Curio, Moxie, BubblePal	0–35%	При цене устройства \$150+ и подписке, продающей лицензированный контент и обучение. Единственный игрок с подтверждённым масштабом — Miko, и его подписка устроена именно так
D. IP hardware	Как правило, ничего	Anki, Jibo, Hello Barbie, Aristotle	0%	При рознице от \$150 и нулевой облачной составляющей на весь срок жизни базы. Ни один из перечисленных этого условия не выдержал

Наблюдение, общее для всех четырёх: разделительная линия проходит не по качеству технологии и не по силе бренда, а по тому, **существует ли объект или услуга, за которую платят повторно**. Сценарий 5 в разделе 11 добавляет пятую форму — роялти с лицензиата, — которая в этой таблице не представлена, потому что на рынке детских устройств её пока никто не использует.

03 — Benchmarks

Шестнадцать кейсов в одной таблице

Сравнительная матрица по параметрам исходного брифа. Прочерк означает, что компания не раскрывает показатель. Attach rate приведён как отраслевой бенчмарк категории content device; ориентиры этого проекта — в разделе 15.

ПРОДУКТ	ТИП	ЦЕНА HW	IP	ПОДПИСКА	RECURRING	ДОП. ПОКУПКИ	AI	НАБЛЮДЕНИЯ
Toniebox 2	Content device	\$140	350+ лицензий	mytonies	74%	Фигурки \$17,99	Генератор историй в тесте	Повторных покупок ~5,7 на активное устройство в год; EBITDA 8,6%
Toniebox Lite	Content device	н/д	те же	та же	—	те же фигурки	—	Запуск 2026: снижение порога входа, второе устройство в семью
Yoto Player 3	Content device	\$110	Мульти-IP	Yoto Club от \$4,99	~60%	Карточки \$7–30	Нет	Подписка 25% выручки; продаёт кредиты на физические карточки, скидки и доставку
Yoto Mini	Content device	\$70	Мульти-IP	та же	~60%	те же карточки	Нет	Дешёвая точка входа в ту же библиотеку — второе устройство, не замена
Storypod	Content device	~\$100	Мульти + свой	\$10–22,50/мес	высокая	Crafties, карточки	Ограниченный	Подписка организована как возрастные наборы, приходящие по мере взросления
Lunii	Content device	~\$70–90	Свой	Нет	средняя	Цифровые альбомы	Нет	Цифровой носитель дешевле в производстве, слабее как подарок
Faba	Content device	~\$80	Мульти	Нет	средняя	Фигурки-персонажи	Нет	Механика Tonies на локальном итальянском контенте
Echo Dot Kids	Ecosystem	\$60 (часто \$38)	Мульти	Kids+ \$2,99–5,99	н/д	Нет	Alexa + LLM	Девайсное подразделение: – \$25 млрд за 2017–2021
Miko 3 / Mini	AI companion	\$150–249	Disney, PBS и др.	Miko Max \$14,99	растёт ×29 г/г	Контент-паки	Да, ядро продукта	~\$43 млн выручки; подписка продаёт лицензированный контент и обучение
Curio Grok / Grem	AI companion	\$99	Свой	Заявлено «не нужна»	~0%	Нет	Да, ядро продукта	Обзоры: интерес спадает в первую неделю, сбои распознавания речи детей до 5 лет, нет офлайна

ПРОДУКТ	ТИП	ЦЕНА	HW	IP	ПОДПИСКА	RECURRING	ДОП.	ПОКУПКИ	AI	НАБЛЮДЕНИЯ
BubblePal (Haivivi)	AI companion	\$89–150		Мульти-персонажи	Нет	~0%	Нет		Да, ядро продукта	200 тыс.+ устройств; подвеска к чужой игрушке снимает стоимость плюша. Компания лицензирует Ultraman и Peppa Pig, модель речь-в-речь покупает у Volcano Engine, рантайм строит сама
FoloToy Kumma	AI companion	\$99		Свой	Нет	~0%	Нет		Да, на OpenAI	Снят после отчёта PIRG, доступ к моделям отозван, возвращён после аудита
Moxie †	AI companion	\$799		Свой	Была	—	Нет		Да, полностью в облаке	Серверы отключены, устройства перестали работать; офлайн-режима не было
Anki Cozmo / Vector †	IP hardware	\$179 / \$249		Свой	Нет	0%	Нет		Компьютерное зрение	\$260 млн инвестиций, миллионы устройств, нулевая recurring выручка
Jibo † / Kuri †	IP hardware	\$700–900		Свой	Нет	0%	Социальный робот		Цена железа не покрывалась ничем после продажи	Закрыты 2018
Mattel Aristotle †	Ecosystem	не вышел		Mattel	Планировалась	—	Планировались		Голосовой ассистент	Отменён в октябре 2017 до релиза после кампании о приватности
† компания прекратила деятельность или продукт снят с рынка. Цены — retail в США на середину 2026 г. «Recurring» — доля выручки, не приходящейся на продажу устройства.										

04 – Требования к ТЗ

Что провалы предшественников означают для технического задания

Каждый разобранный случай даёт проверяемую строку требований. Приоритет P0 означает, что требование закрывается до выпуска и входит в состав работ соответствующей фазы.

ИСТОЧНИК ТРЕБОВАНИЯ	ЧТО ПРОИЗОШЛО	ТРЕБОВАНИЕ	КАК ПРОВЕРЯЕМ	ПРИОРИТЕТ
Moxie	Устройство за \$799. Компания прекратила деятельность в ноябре 2024 после выхода инвестора; 30 января серверы отключили. Распознавание, диалог и эмоциональный вывод выполнялись только в облаке, офлайн-режима не было — устройства перестали работать полностью	Офлайн-режим обязателен. Устройство остаётся функциональным без облака: предзаписанная библиотека, локальные сценарии, локальное пробуждение	Полный сценарий использования воспроизводится при отключённой сети	P0
FoloToy Kumma	Устройство за \$99 на моделях OpenAI. В ноябре 2025 отчёт PIRG показал выдачу недопустимого контента; доступ к моделям отозван, продажи приостановлены, возобновлены через неделю после аудита	Многослойная модерация на входе и выходе, детектор выпадения из образа, откат на утверждённые реплики	Ноль критических инцидентов на корпусе не менее 5 000 часов диалога	P0
Curio, китайский сегмент	Обзоры фиксируют спад интереса в первую неделю; отмечаются длинные ответы, сбои распознавания речи детей младше пяти лет, отсутствие песен и структурированных игр	Ритуал вместо новизны: структурированные сценарии, песни, игры, повторяющиеся форматы с предсказуемым началом и концом	D30/D1 не ниже 45%	P0
Anki, Jibo, Kuri	Cozmo \$179, Vector \$249, Jibo \$899. Все три закрылись в 2018–2019; Anki привлёк около \$260 млн. Повторяющегося платежа в модели не было	Повторяющийся платёж заложен в модель до заказа оснастки — в одной из трёх форм по разделу 12	Источник повторяющегося платежа выбран и оценён в финмодели до размещения заказа на оснастку	P0
Aristotle, Hello Barbie	Aristotle отменён в октябре 2017 под давлением родительских организаций ещё до выхода; петицию подписали более 1 500 человек. Hello Barbie — коллективный иск и претензии по COPPA	Приватность как публичная позиция: архитектура данных и коммуникация проектируются до анонса	Модель хранения, состав данных и родительские права описаны публично на момент анонса	P0

ИСТОЧНИК ТРЕБОВАНИЯ	ЧТО ПРОИЗОШЛО	ТРЕБОВАНИЕ	КАК ПРОВЕРЯЕМ	ПРИОРИТЕТ
Amazon	Убыток девайсного подразделения около \$25 млрд за 2017–2021 при стратегии продажи железа около себестоимости в расчёте на экосистемную выручку	Платформенный слой строится на подтверждённых метриках первой вертикали, а не параллельно с ней	Платформенные работы планируются по ориентирам раздела 15, после первой вертикали	P1

05 — Регуляторный контур

Мир и Россия

Требования, влияющие на архитектуру данных и сроки. Российский контур существеннее для первой фазы, мировой — для переносимости.

НОРМА	ЮРИСДИКЦИЯ	СТАТУС	ЧТО ОЗНАЧАЕТ ДЛЯ ПРОДУКТА
152-ФЗ	Россия	Действует	Обработка данных ребёнка — только с согласия законного представителя. Согласие должно быть информированным, добровольным и отзываемым, с указанием целей, объёма данных, сроков и получателей. Обработка данных несовершеннолетних и биометрических данных отнесена к категориям, требующим согласования нормативных актов с уполномоченным органом. Родительское согласие, политика хранения и возможность отзыва встраиваются в продукт
Голос как биометрия	Россия	Действует	Требует отдельной проработки: голосовая запись ребёнка при определённых способах обработки попадает в режим биометрических данных с повышенными требованиями. Архитектурный вывод — не хранить сырое аудио дольше времени обработки и по возможности не выносить его за пределы устройства
Toy Safety Regulation 2025/2509	ЕС	В силе с 01.01.2026	Обязательный цифровой паспорт продукта вместо декларации о соответствии. Игрушка со встроенной AI-системой попадает под регулирование. Релевантно на фазе выхода на внешние рынки
Обновлённые правила COPPA	США	Полное соблюдение с 22.04.2026	Опубликованы 22.04.2025, вступили в силу 23.06.2025, срок приведения в соответствие — 22.04.2026. Голосовой отпечаток прямо отнесён к персональным данным наравне с отпечатком пальца и рисунком лица. Появилось исключение для аудиозаписи голоса ребёнка : её можно собирать без родительского согласия, если она служит исключительно ответом на конкретный запрос ребёнка, никакие другие персональные данные не собираются и файл удаляется сразу после ответа. Обязательны письменная политика хранения со сроками удаления и письменная программа информационной безопасности. Для передачи данных третьим лицам сверх необходимого для работы сервиса нужно отдельное согласие
Children's AI Toy Safety Act of 2026 (S. 5171)	США	Внесён	Федеральные стандарты для AI-продуктов детям до 13 лет: сбор данных, генерация контента, влияние на психическое здоровье; надзор у FTC. Предполагает инвентаризацию всех AI-функций, включая распознавание голоса и генеративный контент
Законы штатов об AI-чатботах	США	Приняты и вносятся	Раскрытие факта общения с AI, в ряде норм с почасовыми напоминаниями; механизмы реакции на признаки самоповреждения

Общее для обоих контуров

Требования сходятся к одной архитектурной развилке: где обрабатывается голос ребёнка. Локальная обработка снимает большую часть вопросов и в 152-ФЗ, и в COPPA, и в законопроекте S. 5171 одновременно — но переносит стоимость с облака на себестоимость устройства. Развилка количественно разобрана в разделах 08 и 13.


06 — Экономика категории

Раскрытые цифры и что они задают

Tonies — единственная публичная компания категории. Её отчётность используется как опорная точка для оценки потолка модели.

Структура выручки по источникам

tonies — раскрытые данные FY2025. Yoto — по публичным заявлениям компании.



У tonies подписка и цифра — 3,4%, подпись не помещается в сегмент. За десять лет цифровое направление не стало значимым.

ПОКАЗАТЕЛЬ	ЗНАЧЕНИЕ	КОММЕНТАРИЙ
Выручка FY2025	€630,3 млн	+31% г/г, +36% в постоянной валюте
Валовая маржа	62,8%	Логистика, курс, микс
Скорр. EBITDA	8,6%	Рекорд компании; операционные расходы съедают 86% валовой прибыли
Свободный денежный поток	−€11,9 млн	Против +€33,1 млн годом ранее
Лицензионные отчисления	11,0%	€69,4 млн — планка доходности для собственной модели
Повторных покупок на устройство в год расч.	~5,7	Отраслевой бенчмарк архетипа А. Yoto заявляет «более 3»
Чистая выручка с единицы контента расч.	~€8,0	При рознице ~\$17,99 бренд получает 45–50%
Чистая выручка с устройства расч.	~€42	При рознице \$99–140 — около 40% от полки
Выручка на активное устройство в год расч.	~€64	Столько «стоит» одна семья в год для платформы
Отношение контент / железо	2,8×	За срок жизни: ~€106 контента против ~€42 железа
расч. — не раскрывается компанией, получено из разницы накопленных величин между отчётами FY2024 и FY2025. База 2024 указана компанией как «более 8 млн» и «более 100 млн», поэтому производные — верхняя граница.		

Из этих цифр следуют два ограничения на конструкцию.

Первое — планка. Лицензиары в этой модели получают 11,0% выручки экосистемы при нулевых вложениях. Собственная конструкция имеет экономический смысл при доходности выше этой отметки; сценарий 5 в разделе 11 построен так, чтобы добавить к роялти вторую строку — маржу на пропускаемом инференсе.

Сегмент AI-игрушек при этом выглядит доходнее классических аудиоустройств: отраслевые оценки дают **50–65% валовой маржи** в массовом сегменте 300–400 юаней, 70–85% в среднем и свыше 90% в премиальном. Величины разной природы — валовая маржа против EBITDA у Tonies, — и напрямую их сравнивать нельзя, но потолок категории они поднимают. Показательно распределение внутри цепочки: контрактные производители зарабатывают «несколько юаней» с изделия, продающегося за несколько сотен, то есть стоимость концентрируется у владельца бренда и прав.

Второе — канал. Из розничной цены до владельца продукта доходит около 40%: игрушечная розница берёт 40–60% валовой маржи, дистрибьюторы ещё 20–40% сверх закупки, возвраты электроники составляют 3–15% при стоимости обработки \$30–65 за штуку. Это одинаково верно для любого сценария и учтено в разделе 13.

Себестоимость минуты: мировой и российский стек

Расчёт диапазонный, по опубликованным прайс-листам на середину 2026 года, для трёх профилей нагрузки.

КОМПОНЕНТ	ОПТИМИЗИРОВАННЫЙ	БАЗОВЫЙ	ПРЕМИАЛЬНЫЙ
ASR	\$0,004	\$0,006	\$0,012
LLM	\$0,012	\$0,030	\$0,060
TTS	\$0,011	\$0,015	\$0,036
Модерация	\$0,003	\$0,004	\$0,002
Итого за минуту	\$0,030	\$0,055	\$0,110
Мировой стек. Оптимизированный — малая модель, бюджетный TTS, кэширование. Базовый — модель среднего класса и качественный голос. Премиальный — фронт-модель и синтез уровня ElevenLabs. Модерация добавляет 15–25% к стоимости LLM и учтена.			

КОМПОНЕНТ	GIGACHAT LITE	GIGACHAT PRO	GIGACHAT MAX
ASR — SaluteSpeech	1,20 ₺	1,20 ₺	1,20 ₺
LLM	0,43 ₺	3,24 ₺	4,10 ₺
TTS — SaluteSpeech	0,53 ₺	0,53 ₺	0,53 ₺
Модерация	0,09 ₺	0,65 ₺	0,82 ₺
Итого за минуту	2,25 ₺	5,62 ₺	6,65 ₺
Российский стек: SaluteSpeech (распознавание 1 200 ₺ за 1 000 минут, синтез 1 000 ₺ за 1 млн символов, с НДС) и GigaChat. Допущения расчёта: 8 реплик в минуту по ~270 токенов, ассистент говорит ~35 секунд из минуты при ~15 символах в секунду, модерация +20% к LLM.			

Расчёт не подтверждает ожидание, что российский стек дешевле

При сопоставлении по курсу 80 ₺ за доллар — курс принят как *допущение расчёта* — стеки практически совпадают:

- мировой оптимизированный — **2,40 ₺/мин**, российский на Lite — **2,25 ₺/мин**;
- мировой базовый — **4,40 ₺/мин**, российский на Pro — **5,62 ₺/мин**.

Разница внутри погрешности допущений. Покомпонентно картина неоднородна: **LLM в России дешевле** (GigaChat Lite — 0,20 ₺ за 1 000 токенов, порядка \$0,0025), синтез сопоставим, а **распознавание речи дороже примерно в 3,5 раза** (1,20 ₺/мин против \$0,0043 у Deepgram). Экономия на модели гасится переплатой за распознавание.


Формулировка «старт в России улучшает удельную экономику» на этих данных не подтверждается как факт и приводится ниже как **условие**: при каких допущениях она становится верной.

Что помещается в российскую подписку

Ориентир цены детской подписки на российском рынке — Яндекс Плюс 399 ₺ в месяц. Ниже — сколько минут живого диалога в день уместается в бюджет AI при разных ценах и целевой марже, на самом дешёвом стеке.

Допустимая квота живого диалога, минут в день

Стек GigaChat Lite при 2,25 ₽ за минуту. Для сравнения — квота, которую позволял мировой расчёт при подписке \$7,99.



Это главный количественный вывод раздела. При российских ценах на подписку **в бюджет помещается 1,2–3,7 минуты живого диалога в день** — то есть в четыре-двенадцать раз меньше, чем допускал мировой расчёт. Причина не в дороговизне стека, а в цене подписки: 399 ₽ примерно вдвое ниже \$7,99.

Три условия, при которых конструкция сходится

Ни одно из них не про выбор поставщика моделей — все три про архитектуру:

- **Гибридная архитектура.** 80–90% времени использования несёт предзаписанный контент с нулевой предельной себестоимостью; живая генерация занимает 10–20%. При 45 минутах использования в день это 4,5–9 минут генерации — что уже сопоставимо с квотой, помещающейся в подписку 399–499 ₽.
- **Бандл вместо отдельной подписки.** При включении в существующую подписку с большим ARPU бюджет AI перестаёт упираться в цену отдельной строки, а отток считается по всей подписке. Гипотеза Н6.
- **Локальный инференс.** Перенос распознавания и синтеза на устройство убирает самую дорогую компоненту российского стека — ASR за 1,20 ₽/мин — и одновременно снимает бóльшую часть вопросов 152-ФЗ о голосе ребёнка. Стоимость переезжает в себестоимость железа; развилка количественно разобрана в разделе 12.

При выполнении всех трёх старт в России действительно даёт лучшую удельную экономику, чем старт на мировом рынке — за счёт архитектуры и бандла.

Языковой контур: что доступно с полки, а что придётся делать

Дешёвые приёмы, на которых стоит китайский рынок, упираются в язык. Два из них проверены отдельно:

- **Сквозная модель речь-в-речь.** Real-time speech model Doubao от Volcano Engine принимает звук и отдаёт звук без промежуточного текста, сохраняя интонацию и эмоцию, и стоит дёшево. Ориентирована на китайский, поддерживает английский; многоязычный диалог пока не поддерживается, русского нет. Доступна только как облачный API.
- **Офлайновые команды на устройстве.** В библиотеке ESP-SR у Espressif языковая привязка различается по компонентам. Обработка звука — шумоподавление, детектор речи, эхоподавление, локализация источника по двум микрофонам — язык не различает и работает с русским. Пробуждение по ключевому слову (WakeNet) обучается под конкретное слово, до пяти на модель; русское слово заказывается отдельно, и это проект: нужен корпус от 20 тыс. пригодных записей от более чем 500 человек, включая не менее 100 детей, с дистанций 1 и 3 метра, по 30 повторов на диктора; обучение занимает две-три недели после сдачи корпуса, цена зависит от числа слов и тиража. Распознавание команд (MultiNet) поддерживает китайский и английский без смешивания. Синтез речи в составе ESP-SR — только китайский.

Отсюда следствия для первой фазы. Каскад SaluteSpeech и GigaChat остаётся рабочим маршрутом для России, и расчёт выше сохраняет силу. Вынос частотных сценариев на устройство превращается из бесплатного приёма в статью работ: под русский нужен свой распознаватель команд, а ключевое слово — заказная разработка со своим корпусом.

У этой статьи есть побочная выгода. Корпус детской речи, который потребуется для русского ключевого слова, — от 500 дикторов, не менее 100 из них дети, — это тот же материал, на котором проверяется гипотеза НЗ о распознавании речи детей 3–5 лет и обучается собственный локальный распознаватель. Один сбор данных закрывает три задачи, и он же остаётся у компании как актив, которого нет у решений с полки.

Месячная себестоимость на активное устройство, Россия

ПРОФИЛЬ	GIGACHAT LITE	GIGACHAT PRO	КОММЕНТАРИЙ
Гибрид, 4,5 мин/день	304 ₽	759 ₽	Помещается в подписку 499 ₽ только на Lite и только при марже ниже 40%
Light, 5 мин/день	338 ₽	843 ₽	—
Normal, 15 мин/день	1 012 ₽	2 529 ₽	Не покрывается ни одной реалистичной ценой отдельной детской подписки
Heavy, 40 мин/день	2 700 ₽	6 744 ₽	Требует жёсткой квоты независимо от модели монетизации
Без учёта облака, хранения и поддержки — только инференс. Строка «Гибрид» соответствует 10% живой генерации при 45 минутах использования в день.			

Разбивка выше построена на каскаде из распознавания, модели и синтеза. Сквозные речевые модели тарифицируются иначе и ломают это разложение — при выходе на рынки, где они доступны, себестоимость нужно пересчитывать заново.

Цены на инференс за 2024–2026 годы снижались, и расчёт стоит пересматривать ежеквартально. Прогнозов стоимости на будущие периоды ни один из перечисленных поставщиков не публикует, поэтому в модели раздела 13 снижение не заложено.

Рынок, канал, прецедент и что переносится дальше

Первая фаза идёт в России. Ниже — параметры этого рынка и граница между тем, что на нём проверяется для всех рынков, и тем, что действует только здесь.

Рынок умных колонок РФ

48 млрд ₽2025 год, рост 10% за год

Ценовая точка

5 000–10 000 ₽VK Капсула Нео от 5 000 ₽, Яндекс Станция Лайт 2 — 8 799 ₽, Мини 3 — 9 999 ₽

Ориентир подписки

399 ₽/месяцЯндекс Плюс; 3 490 ₽ при годовой оплате

Детские устройства с IP

Категория заняталицензионные устройства с персонажами присутствуют в рознице; голосовой слой в них, как правило, партнёрский

Что даёт российский рынок как площадка первой фазы

Полный стек в одних руках. Это единственный рынок, где компания может держать одновременно контент, канал, платежи и отношения с семьёй. На выходе получаются не столько продажи, сколько измеренные величины: реальная себестоимость минуты, удержание, история безопасности, отложенный канон.

Ценовая структура иная, чем в мировом расчёте. Устройство в диапазоне 5 000–10 000 ₽ и подписка около 399 ₽ — это примерно вдвое ниже долларовых ориентиров при сопоставимой себестоимости инференса. Отсюда жёсткость квоты, посчитанная в разделе 07, и отсюда же ценность бандла и локального инференса именно здесь.

Один регуляторный контур вместо трёх. На первой фазе достаточно соответствия 152-ФЗ; цифровой паспорт ЕС, COPPA и законы штатов подключаются на фазе выхода наружу. Это экономит время первой фазы, но создаёт риск: архитектура данных, спроектированная только под 152-ФЗ, может не пройти в ЕС и США без переделки. Поэтому политика хранения проектируется по строгому из контуров сразу — см. раздел 12, статья «сервис памяти».

Подписка: бандл вместо отдельной строки

Отдельная детская подписка наследует отраслевой отток 7,4% в месяц, причём две главные причины отписки — «ребёнок потерял интерес» (36%) и «перерос контент» (24%) — устройством не лечатся.

Альтернатива, требующая проверки: включение в подписку с большим ARPU вместо отдельной строки в чеке. Тогда отток считается по всей подписке, а детский модуль работает на её удержание. Проверяется на пилоте — гипотеза H8.

Что переносится на внешние рынки, а что нет

Переносится

- Канон персонажа и правила его удержания
- Приёмочный набор и история безопасности — измеренная на реальных часах диалога
- Метрики удержания и структура квоты
- Голосовой пайплайн и тембр — при наличии прав на голос за пределами РФ
- Фабрика контента и её выработка

Не переносится

- Поставщики моделей, распознавания и синтеза
- Облачный контур и размещение данных
- Платежи и биллинг подписки
- Регуляторное соответствие: 152-ФЗ не даёт ни COPPA, ни цифрового паспорта ЕС
- Каналы продаж и партнёрская экосистема
- Ценовая точка и структура бандла

- Сам факт работающей инсталляции с измеренными показателями

Граница проходит не по функциям, а по тому, привязан ли компонент к юрисдикции и поставщику. Всё, что привязано, переделывается на каждом рынке — и это отдельная статья затрат, см. раздел 12.

09 – Ландшафт платформ

Кто уже продаёт инструментарий

Проверка на то, что предлагаемая архитектура индустриально стандартна, и на то, какая её часть остаётся незанятой.

ПЛАТФОРМА	ЧТО ЗАКРЫВАЕТ	ЧЕГО НЕ ЗАКРЫВАЕТ	РЕЛЕВАНТНОСТЬ
Tuya	AIoT-платформа с готовым решением для AI-игрушек: конструктор агента с настройкой личности, логики памяти и поведения без обучения моделей; AI-модули и AI-боксы; подключение к ChatGPT, Gemini, DeepSeek, Qwen, Doubao; 60+ языков; родительское приложение с мониторингом диалогов; преднастроенные каркасы GDPR и CCPA. Заявляет выход в серию от 15 дней и экономию 30–50% расходов на разработку, включая путь кастомизации под бренд-IP	Канон конкретного персонажа, его голос, приёмку и права. Конструктор личности — это пустая форма, которую нужно чем-то наполнить	Подтверждает, что рантайм и адаптеры — покупаемый товар. По имеющимся данным для российского рынка недоступна
Inworld AI	Ближайший аналог слоя персонажа. Компания сместилась из чистого слоя персонажа в инфраструктуру: Runtime — высокопроизводительный графовый движок на C++ с SDK для Node.js и Unreal, оркестрирующий LLM, распознавание, синтез, память и инструменты в одном конвейере, с удалённой перенастройкой без передеплойа. Плюс собственные Realtime TTS и STT и роутер к 220+ моделям	Права на персонажа и его аудиторию	Прямой урок: ценность утекает в рантайм и приёмку. Конфигурации персонажа и прав оказалось недостаточно, чтобы удержать позицию, и компания ушла вниз по стеку
Слой оркестрации и голоса	LiveKit, Pipecat, Cartesia, ElevenLabs, платформы автоматической оценки качества диалога. Транспорт реального времени, конвейеры голосовых агентов, синтез, регрессионное тестирование поведения	Всё предметное: персонаж, канон, контент, приёмка под конкретный бренд	Подтверждает, что архитектура из раздела 12 — индустриальный стандарт, а не изобретение под этот проект. Компоненты берутся готовыми
Российский контур	GigaChat и SaluteSpeech у Сбера, YandexGPT и SpeechKit в Yandex AI Studio — модели, распознавание и синтез с размещением внутри страны	Готового решения уровня Tuya для AI-игрушек в открытом доступе не обнаружено: конструктора агента, модулей и родительского контроля пакетом нет	На российском рынке слой оркестрации придётся собирать самостоятельно из компонентов — это часть CAPEX фазы 1

Вывод раздела: **инструментарий на рынке есть, и переписывать его не нужно**. Рантайм, транспорт, синтез и оценка берутся готовыми там, где доступны, и собираются из компонентов там, где готового пакета нет.

Незанятое место — **наполнение, канон и приёмка**. Оно завязано на права, и в случае этой франшизы права есть только у одной компании. Траектория Inworld показывает и обратное: удержать позицию только на конфигурации персонажа не удалось — значит, слой персонажа имеет смысл строить вместе с рантаймом и приёмкой, а не как надстройку над чужим.

10 – Возрастной разрыв

Арифметика ограничения и что его смягчает

Ядро аудитории франшизы — дошкольники 2–6 лет. Это лучший преддошкольный бренд в мире по данным Parrot Analytics: 100 млрд просмотров, топ-10 самых востребованных шоу планеты в 2024 году, присутствие в 150+ странах.

Устройству для окупаемости нужно 3–5 лет активной жизни в семье. Ребёнок, получивший его в 3 года, выходит из ядра примерно в 6 — **в середине жизненного цикла устройства**. Отраслевые данные это подтверждают: в детских образовательных подписках 24% отписок приходится на «перерос контент» и 36% — на «потерял интерес».

Ограничение структурное: оно влияет на срок окупаемости и на то, какая метрика считается успехом. Ниже — варианты смягчения внутри франшизы, без выхода на внешние права.

Вариант	Механика	Что требуется
Форматы внутри вселенной	Спин-оффы, сказки, страшилки, песни — разные форматы для разных возрастов при одном наборе персонажей	Аудит библиотеки: сколько часов качественного аудио набирается сегодня и сколько нужно допроизвести
Обучающие сценарии	Формат, где ценность для родителя растёт вместе с ребёнком: счёт, буквы, английский. У Miko подписка держится именно на этом	Методическая проработка и отдельная приёмка обучающего контента
Взрослеющая линейка	Сложность сценариев и лексика привязаны к профилю ребёнка в сервисе памяти и растут вместе с ним	Возрастная адаптация реализуется как функция рантайма и входит в состав ядра, раздел 12
Второе устройство в семью	Младший ребёнок наследует каталог. У Yoto эту роль играет Mini, у tonies — анонсированный Lite	Привязка каталога к аккаунту семьи
Фабрика контента	Производство озвученного контента из библиотеки и канона снижает стоимость пополнения каталога и позволяет закрывать возрастные пробелы быстрее	Входит в состав ядра, раздел 12
Все варианты опираются на материал, права на который уже принадлежат компании. Оценка объёма каталога в часах требует внутреннего аудита — гипотеза H8.		

Ни один из вариантов не устраняет разрыв полностью — они переносят точку выхода ребёнка из продукта вправо. Насколько именно — измеряется когортно на первой фазе и входит в ориентиры фазы 2, раздел 15.

11 – Сценарии


Пять конструкций и условия каждой

Сценарии 1–4 считаются на одно проданное устройство за три года в базовых допущениях. Сценарий 5 измеряется в другой единице — на лицензиата — и приведён отдельно.

Валовая прибыль на одно устройство за три года, сценарии 1–4

Базовые допущения: 4 единицы контента в год по \$5,90 валовой прибыли, подписка \$7,99 при 30% проникновения, удержание 65% год к году, розничный канал.

■ Устройство
 ■ Контент
 ■ Подписка



СЦЕНАРИЙ 1 Hardware-only

РАБОТАЕТ ПРИ РОЗНИЦЕ ОТ \$150

Вся экономика — маржа с продажи. При BOM около \$30 и рознице \$99 через розницу остаётся около \$13 валовой прибыли на устройство, через DTC — \$52, но CAC \$25–45 съедает почти всё. Итог \$4–14 на устройство, из которых оплачиваются разработка, оснастка, сертификация и облако на весь срок жизни базы. Условие жизнеспособности — розница от \$150 и нулевая облачная составляющая. Кейсы Anki, Jibo и Kuri показывают, что происходит, когда условие не выполнено.

СЦЕНАРИЙ 2 Hardware + подписка

РАБОТАЕТ ПРИ COGS НИЖЕ \$1,50 И ПОДПИСКЕ НА КОНТЕНТ

За три года даёт около \$24 валовой прибыли на устройство при 30% проникновения и оттоке 7% в месяц. Выходит в плюс при удельной себестоимости AI ниже \$1,50 на активное устройство в месяц — что достигается гибридной архитектурой из раздела 07 — и при условии, что подписка продаёт контент и обучение: так устроен Miko Max за \$14,99 с библиотекой Disney и PBS. На российских ценах подписки требования к квоте жёстче, см. раздел 07.

СЦЕНАРИЙ 3 Hardware + экосистема контента

РАБОТАЕТ ПРИ КАТАЛОГЕ В ТЫСЯЧИ НАИМЕНОВАНИЙ

Устройство → контент → персонажи → повторные покупки

Логика Tonies и Yoto: около \$50 на устройство за три года при 4 покупках в год. Условие — каталог масштаба, который у Tonies составляет ~1 500 фигурок и 3 500+ цифровых наименований, накопленных за десять лет. Носителем могут быть фигурки персонажей, карточки эпизодов, сезонные и подарочные наборы. Ориентир цены — \$14,99–19,99 за фигурку при себестоимости носителя \$2,50–3,50.

СЦЕНАРИЙ 4 Платформа

РАБОТАЕТ ПОСЛЕ ПОДТВЕРЖДЕНИЯ МЕТРИК ПЕРВОЙ ВЕРТИКАЛИ

колонка + приложение + TV + игры + AI + подписка + контент → один аккаунт

Сценарий 3 плюс подписочный слой: около \$83 на устройство за три года через розницу и до \$104 через DTC. Даёт прямые отношения с семьёй, first-party данные и собственный канал дистрибуции контента. Условие — строить после подтверждения метрик первой вертикали: обратный порядок стоил Amazon около \$25 млрд.

ядро → референс-инсталляция → пакет с доказательствами → лицензиаты

Компания разрабатывает и держит слой персонажа — канон, голос, память, рантайм и приёмку — и лицензирует его производителям устройств так же, как сегодня лицензирует изображение персонажа. Россия работает как референс-инсталляция: единственный рынок, где стек держится целиком и где измеряются себестоимость минуты, удержание и история безопасности. Дальше наружу уходит не разработка, а право с доказательствами.

Отличие от остальных четырёх: выручка не привязана к количеству устройств, проданных самой компанией. Она привязана к количеству устройств, проданных лицензиатами, и к объёму инференса, проходящего через ядро. Это тот же тип актива, что уже есть у компании, — право.

Почему лицензиат берёт ядро вместе с правами

Технических причин для этого нет: рантайм и адаптеры продаются на рынке, и производитель соберёт их сам. Основание другое — **ядро выполняет лицензионные условия**.

С появлением голоса предметом лицензии становится поведение персонажа: что он говорит ребёнку, как реагирует на трудный вопрос, где отказывается продолжать. Отдавая изображение и голос без контроля над этим слоем, правообладатель принимает на себя риск, цену которого показывает раздел 04: Kumma сняли с продажи за неделю, Aristotle отменили до релиза. Канон, гардрейлы, детектор выпадения из образа и приёмка — это и есть механизм соблюдения лицензии, поэтому они входят в её условия, а не предлагаются лицензиату на выбор.

Отсюда меняется и предмет переговоров. Обсуждается не поставка SDK, а форма лицензии на говорящего персонажа — вместе с тем, чем его поведение гарантируется и как оно принимается перед выпуском SKU.

ТРИ ИСТОЧНИКА ВЫРУЧКИ	УСЛОВИЕ ЖИЗНЕСПОСОБНОСТИ	КАНАЛ
Роялти с устройства, плата за сертификацию SKU, маржа на пропускаемом через ядро инференсе. Расчёт — раздел 13.	Переносимость ядра. Если построенное в России нельзя перенести без переделки, лицензировать нечего. Это отдельная статья затрат, раздел 12.	Ядро отгружается в уже существующую сеть лицензиатов франшизы в разных странах. Компании, которым приходится приобретать права на детские IP по одной сделке, проходят этот путь с другого конца.

ЧТО ПОДТВЕРЖДАЕТ ПРИМЕНИМОСТЬ

Траектория Inworld: ценность в этой нише мигрирует в рантайм и приёмку. Тууа продаёт конструктор личности как пустую форму — наполнение не входит в её предмет. Naivivi лицензирует Ultraman и Реппа

Pig и строит рантайм сама:
сегодня правообладатель этот
слой не предлагает.

12 — Предмет разработки

Что именно строится и во что это обходится

Состав ядра, граница переносимости и три строки затрат вместо одной строки «разработка».

Что называется ядром

Ядро — то, что остаётся неизменным, когда меняется всё остальное. Со временем сменится модель, поставщик синтеза речи, устройство, страна размещения, а однажды и сам герой франшизы. Постоянным обязано остаться другое: **персонаж узнаётся как он сам, держится в пределах канона, помнит ребёнка, звучит своим голосом и не говорит запрещённого**. Всё, что обеспечивает это постоянство, и есть ядро.

Отсюда рабочий признак принадлежности. Функция, которую можно купить у вендора и заменить другим вендором, а персонаж этого не заметит, лежит за пределами ядра. Функция, потеря которой означает, что персонаж перестал быть собой, входит в ядро.

Ядро лежит между двумя заменяемыми слоями. Снизу инфраструктура: модели, распознавание и синтез, облако, платежи, устройство и прошивка. Сверху продукт: конкретное устройство, тарифы, упаковка, розница. Оба слоя свои у каждого рынка и каждого лицензиата, ядро делается один раз.

Переносимое ядро

Разрабатывается один раз, лицензируется дальше. Шесть компонентов разделены по тому, кто с ними работает и как часто они меняются.

- **Character Runtime** — оркестратор диалога: удержание канона, роутинг моделей, гардрейлы на входе и выходе, детектор выпадения из образа, откат на утверждённые реплики. Правят инженеры, редко
- **Конструктор канона** для редакторов — правки персонажа идут без участия разработчиков. Правят редакторы, постоянно
- **Голосовой пайплайн** — тембр, стриминг, перебивание, задержка. Тембр почти неизменен, обвязка меняется вслед за вендорами
- **Сервис памяти** — профиль ребёнка, политики хранения, родительские сводки.

Непереносимый нижний слой

Переделяется под каждый рынок.

- Облако и размещение данных
- Поставщики моделей, распознавания и синтеза
- Платежи и биллинг
- Регуляторное соответствие юрисдикции
- Каналы продаж и партнёры

Переносимость — отдельная статья затрат первой фазы. Если адаптеры моделей, локали и абстракция комплаенса не заложены в фазу 1, зарубежная версия делается заново, и сценарий 5 не работает.

Меняется редко, каждая правка имеет юридические последствия • Приёмочный набор и портал сертификации лицензиатов — механизм, которым лицензия на говорящего персонажа проверяется перед выпуском SKU. Набор сценариев растёт по мере накопления инцидентов • Фабрика контента — производство озвученного контента из библиотеки и канона. Непрерывный производственный процесс	
---	--

Три вектора и что в них одинаково

Рынки различаются набором ограничений, и глубина участия компании в каждом различается вслед за ними.

ВЕКТОР	ФОРМА УЧАСТИЯ	СТЕК	ЧТО ДАЁТ КОМПАНИЯ
Россия	Полная вертикаль: устройство, контент, канал, платежи, отношения с семьёй	Максимально локальный: отечественные модели, распознавание и синтез, размещение данных внутри страны, соответствие 152-ФЗ	Разработку, эксплуатацию и измерения. Это референс-инсталляция, из которой берутся доказательства для остальных векторов
Китай	Монетизация прав. Устройства выпускают лицензиаты с готовыми каналами	Местный и понятный лицензиату: Doubao, TuYa, локальные чипы и производство	Канон, приёмочный набор и условия лицензии. Собственного стека здесь не разворачивается
Остальной мир	Лицензирование, форма определяется по итогам первых двух	Западные поставщики моделей и голоса, требования COPPA, EU TSR и законов штатов	Канон, приёмку и регуляторные оверлеи поведения
Глубина участия задаётся тем, где компания может держать стек целиком и где конкуренция позволяет это окупить.			

Следствие для состава ядра: механизм лицензии в двух формах

Если в Китае лицензиат работает на своём стеке, соблюдение лицензии нельзя обеспечить только своим рантаймом. Механизм должен существовать в двух видах:

- **Рантайм** — реализация для России, где компания держит стек целиком и отвечает за поведение персонажа сама;
- **Спецификация соответствия и приёмочный набор** — то, что чужая сборка обязана пройти перед выпуском SKU. Работает поверх Doubao, Tuuа или любого другого стека лицензиата.

Практически это выглядит так. Лицензиат получает канон как спецификацию поведения — он строит по ней своего персонажа на своём стеке — и обязан прогнать сборку через приёмочный набор, прежде чем выпустить SKU. Ровно так сегодня работает лицензия на изображение: партнёр получает гайдлайн и проходит согласование макета. Рантайм при этом остаётся у компании и в лицензионные поставки не входит.

Это удешевляет фазу 3: на лицензионных векторах достаточно подготовить к передаче канон и приёмочный набор. Оценка в 30 человеко-месяцев и 12–20 на рынок относится к полному переносу стека и нужна там, где компания разворачивает вертикаль сама.

Цена этого решения — приёмка должна судить поведение на чужом языке: канон, проверенный на русских репликах, не подтверждает китайскую сборку. Значит, приёмочный набор нужен с языковыми наборами фикстур и с тем, кто способен оценить результат. Это постоянная строка сопровождения, и она растёт с числом векторов.

Отдельная возможность, возникающая позже: построенная в России вертикаль сама по себе становится тем, чего на этом рынке нет — готового решения уровня Tuuа для AI-игрушек в открытом доступе не обнаружено (раздел 09). Открытие её другим производителям — монетизация внутреннего продукта, и это отдельный бизнес с другим покупателем. Оценивать его имеет смысл после того, как вертикаль работает.

Три строки затрат

СТРОКА	СОСТАВ	ЧТО ПОКУПАЕТ	ОЦЕНКА
CAPEX ядра	Единоразово, по фазам. Разбивка ниже	Актив, который лицензируется	~114 чел-мес
COGS на устройство	Инференс, синтез, облако, модерация — на активное устройство в месяц	Ничего не покупает: это переменная, которую нужно удерживать. Целевое значение — не выше \$1,50, на российском стеке 304 ₺ при гибридной архитектуре	\$1,20–2,50
OPEX сопровождения	Приёмка новых SKU, обновление моделей, поддержка лицензиатов, ведение канона. Постоянная строка, растёт с числом лицензиатов медленнее, чем выручка	Возможность держать качество персонажа при росте числа устройств	3–5 чел постоянно

Против каждой строки CAPEX указано, что она покупает. Оценки в человеко-месяцах — ориентир для планирования, не смета; ставки и стоимость привлечения определяются внутри.

CAPEX ядра по фазам

ФАЗА 1 0–6 МЕС	Character Runtime, канон, голос, память Состав: 2 бэкэнд, 1 ML-инженер, 1 инженер данных, 1 звукорежиссёр, 1 продукт, 1 редактор канона. Что покупает: роутинг и кэш снижают COGS — это единственный способ	42 чел-мес
-------------------	---	------------

удержать себестоимость минуты в рамках раздела 07. Гардрейлы и откат на утверждённые реплики закрывают требование P0 из раздела 04.		
ФАЗА 2 6–12 МЕС	Конструктор канона, приёмка, портал, фабрика контента Состав: 2 бэкэнд, 1 фронтенд, 1 ML, 1 QA-автоматизация, 1 редактор, 1 продукт. Что покупает: конструктор канона снижает OPEX — правки персонажа перестают требовать разработчиков. Приёмка и SDK дают возможность масштабировать выручку через лицензиатов без роста CAPEX. Фабрика контента снижает стоимость пополнения каталога.	42 чел-мес
ФАЗА 3 12–18 МЕС	Переносимость: адаптеры моделей, локали, абстракция комплаенса Состав: 2 бэкэнд, 1 ML, 1 комплаенс, 1 продукт. Что покупает: собственно возможность сценария 5. Эта фаза превращает ядро из российской инсталляции в лицензируемое право.	30 чел-мес
НА КАЖДЫЙ НОВЫЙ РЫНОК	Непереносимый слой Облако, модели, платежи, комплаенс, каналы. Повторяется для каждого рынка и не амортизируется предыдущими.	12–20 чел-мес

Железо ставится в работу с первого дня, параллельно ядру

Фазы выше описывают ядро — программную часть, и она сжимаема. Срок здесь задаётся размером команды, готовыми компонентами из платформенного слоя (раздел 09) и тем, что разработка с помощью нейросетей ускоряется от квартала к кварталу.

Цепочка железа устроена иначе: выбор ODM, промышленный дизайн, оснастка, образцы, сертификация, первая партия. Каждый шаг ждёт предыдущего, и добавленные люди не сокращают ни изготовление оснастки, ни сертификацию. При равном старте эта ветка выходит на результат позже программной.

Вторая причина держать её впереди — железо задаёт рамки ядру. Сколько готового аудио помещается в память офлайн-режима, снимается ли ключевое слово на устройстве, какого качества микрофонный массив стоит перед распознаванием детской речи — это входные условия для фазы 1, а решаются они выбором платы. Практический вывод: трек устройства открывается вместе с фазой 1, и её первым результатом становится выбранная платформа с работающим образцом на руках.

Развилка, которую нужно закрыть до фазы 1

Где выполняется распознавание и синтез — в облаке или на устройстве. Это решение определяет одновременно три вещи: себестоимость минуты, ответ регулятору о голосе ребёнка и требования к железу.

- **Облако:** дешевле железо, но ASR в России стоит 1,20 ₽/мин — самая дорогая компонента стека, и голос ребёнка покидает устройство
- **На устройстве:** убирает ASR из переменных затрат и снимает большую часть вопросов 152-ФЗ, но требует вычислительного модуля, что поднимает BOM и энергопотребление
- **С выгрузкой на телефон родителя:** промежуточный вариант, применяемый в отрасли; требует установленного приложения и близости устройства

Модель раздела 13 посчитана для облачного варианта как консервативного. Локальный вариант меняет структуру: COGS падает, CAPEX и BOM растут; пересчёт — после выбора платформы.

13 — Unit economics

Две модели: на устройство и на лицензиата

Первая описывает сценарии 1–4, вторая — сценарий 5. Они не заменяют друг друга: в конструкции с лицензиатами работают обе одновременно, на разных участках.

Модель А — на устройство, три года

ПАРАМЕТР	КОНСЕРВАТИВНЫЙ	БАЗОВЫЙ	ОПТИМИСТИЧНЫЙ
Вклад устройства после SAC	\$0	\$4	\$10
Единиц контента в год	2,0	4,0	6,5
Проникновение подписки	15%	30%	45%
Цена подписки	\$5,99	\$7,99	\$9,99
Маржа подписки после AI	35%	50%	60%
Удержание год к году	45%	65%	75%
LTV за 3 года	\$26	\$83	\$174
Сценарий 4 через розничный канал. Валовая прибыль с единицы контента — \$5,90 (чистая выручка \$9,00 при рознице \$17,99, маржа 65%). «Удержание» — доля устройств, остающихся активными в следующем году.			

КАНАЛ	SAC	ПРИБЫЛЬ В МОМЕНТ ПРОДАЖИ	ОКУПАЕМОСТЬ	ЧТО КАНАЛ ДАЁТ И ЧЕГО ЛИШАЕТ
Розница	\$4	\$4	сразу	Нет прямых отношений с семьёй и данными; полка забирает около половины цены
Маркетплейс	\$22	\$10	~4 мес	Данные о покупателе принадлежат площадке
ДТС	\$38	\$10	~9 мес	Максимум контроля и данных; требует оборотного капитала и маркетинга
Лицензирование	\$0	~\$9 роялти	сразу	Нулевой риск и нулевой контроль над продуктом. Модель Б добавляет к этому вторую и третью строки выручки
Окупаемость привлечения в базовом сценарии. Ежемесячный поток валовой прибыли — \$3,17: контент \$1,97 плюс подписка \$1,20.				

Модель Б — на лицензиата, в год

Единица счёта — лицензиат. Три источника выручки: роялти с каждого выпущенного устройства, разовая плата за сертификацию SKU и маржа на инференсе, проходящем через ядро.

ТИП ЛИЦЕНЗИАТА	УСТРОЙСТВ В ГОД	РОЯЛТИ	МАРЖА НА ИНФЕРЕНСЕ	СЕРТИФИКАЦИЯ	ИТОГО В ГОД
Малый	25 000	\$125 000	\$54 000	\$15 000	\$194 000
Средний	100 000	\$500 000	\$216 000	\$30 000	\$746 000
Крупный	400 000	\$2 000 000	\$864 000	\$50 000	\$2 914 000
Портфель 1 крупный + 3 средних + 5 малых	725 000	\$3 625 000	\$1 566 000	\$155 000	\$6 122 000
Допущения модели: роялти \$5 с устройства, доля активных устройств 60%, маржа на пропускаемом инференсе \$0,30 на активное устройство в месяц. Все три величины — предмет переговоров и подлежат проверке, см. гипотезы H10 и H11.					

Как устроены продления. Сертификация повторяется при каждом новом SKU и при существенном обновлении моделей. Роялти и маржа на инференсе продолжаютс, пока база активна, — то есть выручка от лицензиата не заканчивается вместе с его продажами, а затухает вместе с его установленной базой. Это отличает модель Б от разового лицензионного платежа.

Как две модели соотносятся. Модель А описывает референс-инсталляцию: устройства, которые компания продаёт сама в России, чтобы получить измеренные величины. Модель Б описывает то, ради чего инсталляция строится. Портфель из девяти лицензиатов даёт порядок \$6 млн в год при 725 тыс. устройств — сопоставимо с тем, что дал бы собственный выпуск 100 тыс. устройств по модели А (\$83 × 100 000 = \$8,3 млн), но **без капитальных затрат на производство, логистику и возвраты** и без САС.

Где модель Б наиболее чувствительна

- Ставка роялти.** Величина переговорная. Ориентир снизу — 11,0%, которые Tonies платит правообладателям с выручки экосистемы
- Доля активных устройств.** Маржа на инференсе начисляется только с активных; при удержании ниже расчётного эта строка падает быстрее роялти
- Готовность лицензиата пропускать инференс через чужое ядро.** Если он захочет свой стек, остаётся только роялти — треть модели. Приёмка и качество канона — единственный рычаг здесь
- Число лицензиатов.** Модель линейна по ним, а OPEX сопровождения растёт медленнее — но только при работающем портале сертификации из фазы 2

Что проверяется, чем и чьими силами

Все проверки выполняются на нашем прототипе и на пилоте: либо нашей командой, либо совместно с заказчиком. Задач, которые заказчик выполняет отдельно от проекта, в списке нет.

№	ГИПОТЕЗА	КАК ПРОВЕРЯЕТСЯ	КТО	ОРИЕНТИР	ФАЗА
H1	Гибридная архитектура удерживает себестоимость	Замер на прототипе: доля времени на предзаписанном контенте против живой генерации, фактическая стоимость минуты на выбранном стеке	мы	≤ 304 ₽/мес	1
H2	Локальный инференс укладывается в целевое железо	Прогон распознавания и синтеза на плате прототипа: задержка, потребление, нагрев, качество против облачного варианта	мы	задержка ≤ 200 мс	1
H3	Распознавание справляется с детской речью 3–5 лет	Полевой тест на русском языке, наш корпус записей; замер доли неуспешных реплик отдельно для облачного и локального распознавания	мы	≤ 10% сбоев	1
H4	Канон устойчив под нагрузкой	Прогон контрольного набора реплик через рантайм: доля ответов, отклонённых детектором выпадения из образа, и доля откатов на утверждённые реплики	мы	≤ 2% отклонений	1
H5	Офлайн-режим покрывает сценарий использования	Полный пользовательский сценарий при отключённой сети на прототипе	мы	сценарий проходит	1
H6	Аудиокаталога хватает на наполнение устройства	Заказчик даёт доступ к аудиобиблиотеке, мы считаем объём в часах, покрытие возрастов и форматов, оцениваем объём допроизводства	мы + заказчик	≥ 100 часов	1
H7	Ритуал удерживает после ухода новизны	Домашний тест прототипа: набор семей формируем совместно, телеметрию и обработку ведём мы	мы + заказчик	D30/D1 ≥ 45%	1

№	ГИПОТЕЗА	КАК ПРОВЕРЯЕТСЯ	КТО	ОРИЕНТИР	ФАЗА
H8	Бандл удерживает лучше отдельной подписки	Сравнение на пилоте: включение в подписку с большим ARPU против отдельной строки в чеке	мы + заказчик	отток ≤ 4%/мес	2
H9	Возрастная адаптация сдвигает точку выхода	Когортный анализ активности по возрасту на пилоте; тест обучающих и взрослеющих форматов	мы + заказчик	≥ 40% на 3-й год	2
H10	Лицензиаты готовы платить за слой персонажа	Переговоры с 3–5 производителями на пакете с измеренными показателями; мы готовим техническую часть пакета и участвуем в переговорах	мы + заказчик	≥ 2 письма о намерениях	3
H11	Лицензиаты готовы пропускать инференс через ядро	Те же переговоры: согласие на использование рантайма и приёмки, а не только канона	мы + заказчик	≥ 50% согласных	3
H12	Приёмка работает поверх чужого стека	Прогон приёмочного набора на сборке лицензиата с другими моделями и другим языком: доля расхождений с каноном, трудоёмкость языкового набора фикстур	мы + заказчик	расхождений ≤ 5%	3
H13	Ядро переносимо без переделок	Пилотная локализация на один внешний рынок: замер доли кода и контента, переносимых без изменений	мы	≤ 20 чел-мес	3
«Мы» — проверка внутри разработки, на прототипе или стенде. «Мы + заказчик» — совместная работа: заказчик даёт доступ к материалу или участвует в переговорах, измерение и обработку ведём мы.					

H1–H5 закрываются на прототипе, собранном в ходе дискавери, и не требуют ни пилота, ни участия заказчика. Они же определяют точность допущений моделей раздела 13: сегодня эти допущения построены на отраслевых бенчмарках, а после H1–H3 — на собственных замерах.

15 — Ориентиры по фазам

Что готово к концу каждой фазы и к каким показателям мы ведём

Рабочие ориентиры команды разработки: к чему мы ведём продукт и о чём отчитываемся на каждом этапе. Решения о составе, приоритетах и продолжении работ принимает заказчик.

ФАЗА 0 ДО СТАРТА	Три совместных решения Выбрана развилка облако / локальный инференс. Выбран и оценён источник повторяющегося платежа. Согласован состав канона и доступ к аудиобиблиотеке. Каждое из трёх меняет состав работ фазы 1, поэтому закрывается до её начала.	3 решения
ФАЗА 1 0–6 МЕС	Работающий рантайм на прототипе и выбранная платформа устройства Character Runtime с гардрейлами и откатом на утверждённые реплики, голосовой пайплайн, сервис памяти, офлайн-режим. Замеры H1–H7. Параллельно идёт трек железа: выбранный ODM или модуль, микрофонный массив и бюджет памяти под офлайн — их результат нужен рантайму уже на этой фазе, а собственная цепочка оснастки и сертификации длиннее программной. Ориентиры: себестоимость ≤ 304 ₺ на активное устройство в месяц; задержка ≤ 200 мс; сбои распознавания детской речи ≤ 10%; отклонений детектором выпадения из образа ≤ 2%; удержание в домашнем тесте прототипа D30/D1 ≥ 45%; ноль критических инцидентов на корпусе не менее 5 000 часов диалога.	42 чел-мес
ФАЗА 2 6–12 МЕС	Приёмка и портал работают без разработчиков	42 чел-мес

Конструктор канона, приёмочный набор, портал сертификации, фабрика контента. Соответствие 152-ФЗ реализовано и проверено до выхода в продажу. Ориентиры: правки канона и сертификация нового SKU проходят силами редакторов, без задач в разработку; отток на пилоте ≤ 4% в месяц при бандле.		
ФАЗА 3 12–18 МЕС	Ядро отделено от рынка Адаптеры моделей, локали, абстракция комплаенса. Пилотная локализация на один внешний рынок. Ориентиры: локализация укладывается в 20 чел-мес непереносимого слоя; техническая часть пакета для переговоров с лицензиатами готова.	30 чел-мес

Как читать эти значения

Все ориентиры — управляемые продуктовые и инженерные величины. Удержание, себестоимость минуты и устойчивость канона улучшаются работой над продуктом: сценариями, квотой, рутином моделей, наполнением каталога. Показатель, не вышедший на ориентир, открывает следующую итерацию.

Отдельно про удержание: до выхода устройства в руки семей его можно мерить только на домашнем тесте прототипа и только на коротком горизонте. Поэтому в ориентирах фазы 1 стоит D30 на тесте. Полугодовые значения появляются после запуска и относятся к развитию продукта.

Требования уровня P0 из раздела 04 — офлайн-режим, многослойная модерация, приватность как публичная позиция — входят в состав фаз 1 и 2 как обязательная часть работ и в этой таблице не дублируются.

Откуда цифры и чему в них верить

Два источника данных. Первый — открытые источники, все со ссылками в конце документа: отчётность публичных компаний, прайс-листы поставщиков, отраслевые публикации, тексты норм. Второй — наше собственное дискавери: прототип устройства с голосовым интерфейсом, собранный и протестированный на предыдущем этапе. Третьего источника в документе нет.

Раскрытая отчётность. Показатели tonies SE — из релизов по итогам FY2024 и FY2025. Это единственный аудируемый источник в категории.

Расчётные величины (помечены расч.) выведены из разницы накопленных показателей. База 2024 указана компанией как «более 8 млн» и «более 100 млн», поэтому производные значения — верхняя граница; реальные могут быть ниже на 5–10%.

Российский стек. Тарифы SaluteSpeech и GigaChat — из документации для разработчиков Сбера. Официальные страницы Yandex AI Studio на момент подготовки были недоступны для автоматического доступа, поэтому цены SpeechKit в расчёт не вошли и требуют сверки. Сопоставление рублёвых и долларовых величин выполнено по курсу 80 ₽ за доллар — это допущение расчёта; при другом курсе выводы раздела 07 о сопоставимости стеков могут измениться.

Границы предмета. В документе намеренно нет данных о внутренних проектах, продуктах и партнёрствах заказчика: то, что не сообщено нам напрямую, в отчёт не включалось. Опыт смежных форматов — приложений, носимых устройств — на проектируемое устройство не переносится и в качестве бенчмарка не используется.

Оценки в человеко-месяцах раздела 12 — ориентир для планирования, построенный от состава команд. Ставки, стоимость привлечения и сроки найма определяются внутри.

Модели раздела 13 — построенные допущения. Все входные параметры выписаны явно, чтобы их можно было оспаривать поштучно. Ставка роялти, доля активных устройств и маржа на инференсе в модели Б — переговорные величины.

Чего в этом документе нет

- Полевых данных: на момент подготовки замеры на прототипе не проводились — это гипотезы H1–H5
- Данных о внутренних проектах и партнёрствах заказчика — вне предмета документа
- Себестоимости устройств: публичные ориентиры существуют только по разборам Echo Dot и Google Home
- Данных о retention по конкретным продуктам категории: их не публикует никто, включая tonies
- Цен SpeechKit и коммерческих условий платформенных поставщиков — ни TuYa, ни Inworld их публично не раскрывают
- Юридической проработки: права на голос за пределами России, форма лицензионного договора на слой персонажа и режим биометрических данных требуют отдельного заключения
- Рекомендаций об устройстве лицензионного бизнеса компании — вне предмета документа

Источники

1. [Отчётность tonies SE за 2025 финансовый год](#)
2. [Тарифы SaluteSpeech — документация Сбера](#)
3. [Тарифы GigaChat API — документация Сбера](#)
4. [TuYa Smart о решениях для AI-игрушек, Spielwarenmesse 2026](#)
5. [Inworld AI о переходе к инфраструктуре и Runtime](#)
6. [IEEE Spectrum: чему учат провалы Anki, Jibo и Kuri](#)
7. [Разбор закрытия Anki](#)
8. [MIT Technology Review о рынке AI-игрушек в Китае](#)
9. [Haivivi BubblePal — характеристики и цены](#)
10. [Регулирование AI-игрушек в ЕС и США — обзор MediaLaws](#)
1. [Children's AI Toy Safety Act of 2026 \(S. 5171\)](#)
2. [Toy Association: федеральные и региональные нормы об AI в игрушках](#)
3. [Рынок умных колонок и голосовых помощников в России — TAdviser](#)
4. [Сравнение детских аудиоплееров: Toniebox, Yoto, Storypod, Timio, Lunii](#)
5. [Parrot Analytics о позиции франшизы в мировом спросе](#)

Отчёт PIRG об AI-игрушках (ноябрь 2025), 152-ФЗ и разъяснения по обработке данных несовершеннолетних, EU Toy Safety Regulation 2025/2509 и правила COPPA цитируются по первичным текстам и отраслевым обзорам,

перечисленным выше. Цены устройств собраны с сайтов производителей и крупных ритейлеров на август 2026 года.

Версия 2, август 2026. Заменяет версию 1. Документ проектный: описывает конструкцию и условия её работоспособности. Валюта — доллары США, где не указано иное; российские величины — в рублях.